Компьютерные науки и анализ данных

Yandex

Faculty of Computer science
Higher School of Economics

Программирование на Python

лектор: Сергей Горшков

План

- Сортировка в Python: sort и sorted
- Параметр key сортировки, operator.itemgetter
- Стабильность (устойчивость) сортировки
- Бинарный поиск в Python: модуль bisect
- Итераторы и генераторы, next и iter
- Модуль itertools

List comprehensions

- list comprehensions: `[func(arg) for arg in iterable if expr(arg)]`

Сортировка в Python

- Для списков: два метода
  - sort – inplace
  - sorted – не изменяет исходный объект, возвращает отсортированную копию
- sorted принимает на вход итерируемое – iterable, кортежи, строки, … Возвращает всегда список
- По умолчанию сортирует по возрастанию, аргумент reverse=True – по убыванию
- Не путать с reversed – возвращает обратный итератор по списку
- Сортировку можно применять к спискам, элементы которых сравнимы между собой, как правило, одного типа (можно int и float вперемешку также)
- Алгоритм Timsort – сортировка вставками + слиянием. O(NlogN) в среднем, O(N^2) в худшем случай

Параметр key сортировки

- Сравнение кортежей происходит поэлементно!
- Можно создать вспомогательные кортежи и отсортировать их
- Но лучше использовать параметр key: функция, которая применяется к каждому элементу списка и сравнение происходит по по значению этой функции (ключ)
- Сортировка в Python обладает свойством устойчивости: для элементов с равным ключом сохраняется их взаимный порядок
- В качестве функций можно использовать любой callable: встроенные функции, пользовательские функции, лямбда-функции
- operator.itemgetter как замена lambda x: x[const]
- functools.cmp_to_key – C-like style, пример

Итераторы и генераторы

- Итератор = Объект, имеющий внутреннее состояние и метод __next__
- Создание из списка – iter(), получение следующего значения – next()
- a = (x for x in range(5) if x % 2 == 1) – создание генератора
- Проход for также будет брать next элемент – умеет обрабатывать StopIteration
- Для создания итераторов используют специальный тип функции – генераторы
- yield вместо return – возвращает значение и приостанавливает выполнение функции пока не потребуется следующий элемент
- Результат работы генератора можно сохранить, например, в список с помощью list
- Модуль itertools – *на следующей неделе*

Бинарный поиск в Python

- Модуль bisect (рус)
- Двоичный поиск на отсортированных массивах
- Поиск элемента за O(logN)
- Вставка за O(N) асимптотически, по факту быстрее, чем линейный поиск
- Метод bisect – поиск места для вставки, insort – вставка элемента в отсортированный массив
- Аргументы lo и hi для поиска на подмассиве

Работа с stdin как с файлом

- Работа со стандартным потоком ввода `sys.stdin`
- Сериализация: pickle и работа с ним в Python
- Использование модулей `io/codecs` для использования кодировки в `open`
- Ещё раз про запись в файл через write (режимы доступа в частности)

bytes и bytearray

- Байтовые строки: создание – префикс `b''` или `bytes(string, encoding=coding)` или `bytes([ord])`
- `string.encode(coding)`
- `bytes_array.decode(coding)` – обратно
- bytearray – изменяемый bytes
- Юникод-сэндвич:
  - байты, которые программа считывает, надо как можно раньше преобразовать в Юникод (строку)
  - внутри программы работать с Юникод
  - Юникод надо преобразовать в байты как можно позже, перед передачей

Pro tip #1: Unicode sandwich

Bytes on the outside, unicode on the inside

Encode/decode at the edges

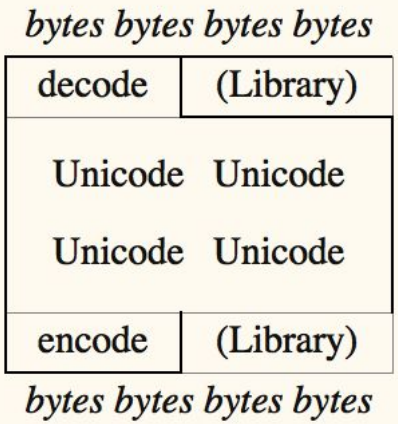

Higher School of Economics
computer science

Регулярные выражения

- Базовое руководство по регулярным выражениям
- Документация
- Методичка + про замены
- Найти в тексте время. Время имеет формат часы:минуты. И часы, и минуты состоят из двух цифр, пример: 09:00. Напишите регулярное выражение для поиска времени в строке: «Завтрак в 09:00». Учтите, что «37:98» – некорректное время.

Faculty of Computer Science
Higher School of Economics

sgorshkov@hse.ru
tg: @Seragor98